




绪论

目录

- NLP概念
- NLP的难点
- NLP的任务体系
- NLP技术发展历史

什么是自然语言处理？

- 语言是**思维的载体**，是人类交流思想、表达情感最自然、最方便的工具
 - 人类历史上大部分知识是以语言文字形式记载和流传的
- 自然语言指的是人类语言，特指**文本符号**，而非语音信号
- 自然语言处理（ Natural Language Processing , NLP ）
 - 用计算机来**理解**和**生成**自然语言的各种理论和方法
 - 属于人工智能领域的一个重要甚至核心分支，是**计算机科学与语言学**的交叉学科，又常被称为计算语言学




什么是自然语言处理？

- 人工智能的发展经历了从**运算**智能到**感知**智能，再到**认知**智能三个发展阶段
- **运算**智能:关注的是**机器的基础运算和存储能力**
 - 机器已经完胜人类
- **感知**智能:则强调机器的**模式识别能力**，如**语音的识别**以及**图像的识别**
 - 目前机器在感知智能上的水平基本达到甚至超过了人类的水平
- **认知**智能：**自然语言处理**以及**常识建模和推理**等研究
 - 机器与人类还有很大的差距

自然语言处理属于认知智能任务

□ **认知智能**是人类和动物的主要区别之一

□ 需要更强的**抽象**和**推理**能力



自然语言处理的代表性应用



机器翻译



"Hey Alexa"



"Hey Siri"


智能助手




文本校对



舆情分析



智能教育



知识图谱

自然语言处理的难点与特点

- 为什么计算机在处理自然语言时会如此困难呢？
 - 有高度的抽象性
 - 近乎无穷变化的语义组合性
 - 无处不在的歧义性和进化性
 - 理解语言通常需要背景知识和推理能力

自然语言处理的难点与特点

领导：“你这是什**意思**？”

阿呆：“没什么**意思**，**意思意思**。”

领导：“你这就不够**意思**了。”


阿呆：“小**意思**，小**意思**。”

领导：“你这人真有**意思**。”

阿呆：“其实也没有别的**意思**。”

领导：“那我就**不好意思**了。”

阿呆：“是我**不好意思**。”



自然语言处理的难点与特点

□抽象性

- 语言是由抽象符号构成
- 每个符号背后都对应着现实世界或人们头脑中的复杂概念
- 如“车”表示各种交通工具——汽车、火车、自行车等
- 它们都具有共同的属性，有轮子、能载人或物等

自然语言处理的难点与特点

□组合性

□每种语言的**基本符号单元**都是有限的

- 英文仅有26个字母

- 中国国家标准GB 2312共收录6,763个汉字

□即便是**常用的单词**，英文和中文也不过各几十万个

□但**有限的符号**却可以组合成**无限的语义**

- 即使是相同的词汇，由于**顺序不同**，组合的语义也是不相同的

 - 李四打了张三

 - 张三打了李四

- 无法使用穷举的方法实现对自然语言的理解

自然语言处理的难点与特点

□歧义性

□语言的形式和语义之间存在多对多的对应关系

□一词多义：“苹果”

- 水果

- 一家公司或手机、电脑等电子设备

□形式不同，语义相同

- “曹雪芹写了红楼梦” “红楼梦的作者是曹雪芹”

- 张三打了李四 李四被张三打了

自然语言处理的难点与特点

□**进化性**：“活着”的语言都是在不断发展变化的

□**词汇**体现：

① 新词汇层出不穷，如“超女” “非典” “新冠”等

② 旧词汇被赋新含义，如“腐败” “杯具”等

□语言的**语法**等也在不断变化，**新的用法**层出不穷

自然语言处理的难点与特点

□ **非规范性**：在互联网上，尤其是在用户产生的内容中，经常有一些有意或无意造成的**非规范文本**

□ **音近词**：“为什么” → “为森么”，“怎么了” → “肿么了”

□ **单词简写或变形**：please → pls、
cool → coooooooooool

□ **新造词**：“喜大普奔” “不明觉厉”

□ **错别字**

□ 为自然语言处理带来了不小的挑战

自然语言处理的难点与特点

□主观性: 如分词任务

- 关于什么是“词”的定义都尚不明确
- “打篮球”是一个词还是两个词呢？

□困难：

□标注数据

- 标注任务的数据，需培训标注人员，非众包的方式招募，数据规模小

□任务难以评价

- 不同分词系统、标准不尽相同、用准确率等客观指标不客观
- 人机对话等任务中对话回复的主观性，很难标准回复
- 如何自动评价人机对话系统是一个开放的问题

自然语言处理的难点与特点

□ **知识性**：理解语言需要背景知识以及基于这些知识的推理能力

□ “张三打了李四，然后他倒了”

□ “他” 指代的是 “张三” 还是 “李四” ？

□ “张三打了李四，然后他笑了”

□ “他” 指代的是 “张三” 还是 “李四” ？

自然语言处理的难点与特点

- ❑ **难移植性**：NLP涉及的任务和领域众多，并且它们之间的差异较大
 - ❑ **基础任务**：分词、词性标注、句法分析和语义分析
 - ❑ **应用任务**：信息抽取、问答系统和对话系统
- ❑ 任务的目标和数据各不相同，很难使用统一的技术或模型针对不同的任务设计不同的算法或训练不同的模型
- ❑ 不同领域的用词、表达方式不尽相同，在一个领域上学习的模型也很难应用于其他领域
- ❑ 增加自然语言处理系统的可移植性难度

“人工智能皇冠上的明珠”

□ 自然语言处理成为**制约人工智能取得更大突破和更广泛应用的瓶颈**

□ NLP被誉为“**人工智能皇冠上的明珠**”，吸引更多人工智能研究者加入



“深度学习的下一个前沿课题是**自然语言理解**”

Yann LeCun

图灵奖得主、Facebook AI 负责人



“深度学习的下一个大的进展应该是**让神经网络真正理解文档的内容**”

Geoffrey Hinton

图灵奖得主、深度学习之父



“如果给我10亿美金，我会用这10亿美金建造一个NASA级别的**自然语言处理**研究项目”

Michael I. Jordan



美国双院院士、世界知名机器学习专家



“下一个十年，**懂语言者**得天下”

沈向洋

美国工程院院士、微软前全球执行副总裁



图灵测试

自然语言处理任务层级



应用系统 (NLP+)

- 教育，医疗，司法，金融，机器人等

应用任务

- 信息抽取，情感分析，机器翻译，对话系统等

基础任务

- 分词，词性标注，句法分析，语义分析等

资源建设

- 语言学知识库建设，语料库资源建设等

□ 资源建设

□ 语言学知识库建设

- 提供词语音韵、句法或者语义解释以及示例等信息
- 提供词语之间的关系信息，如上下位、同义反义关系

□ 语料库资源建设

- 面向某一NLP任务所标注的数据
- 语言学资源和语料库资源的建设，是上层各种自然语言处理技术的基础，需要花费大量的人力和物力构建

自然语言处理任务层级

□ 基础任务：

□ 包括：

- 分词
- 词性标注
- 句法分析
- 语义分析

□ 特点：

- 不直接面向终端用户
- 语言学上的研究价值
- 为上层应用任务提供所需的特征

自然语言处理任务层级

□应用任务：

□包括：

- 信息抽取
- 情感分析
- 问答系统
- 机器翻译
- 对话系统

□特点：

- 可以作为产品直接被终端用户使用

自然语言处理任务层级

- 应用任务：NLP在某一领域的综合应用，又被称为NLP+，即NLP技术加上特定的应用领域
 - 智能教育领域：用文本分类、回归实现主观试题的智能评阅，减轻教师工作量，提高工作效率
 - 智慧医疗领域：NLP技术可以帮助医生跟踪最新的医疗文献，帮助患者进行简单的自我诊断等
 - 智能司法领域：使用阅读理解、文本匹配实现自动量刑、类案检索和法条推荐等
- 凡是涉及文本理解和生成的领域，自然语言处理技术都可以发挥巨大的作用

自然语言处理任务类别

□ NLP任务多种多样，但是这些复杂的任务可归纳为五类问题中的一个

□ 回归问题

□ 分类问题

□ 匹配问题

□ 解析问题

□ 生成问题

自然语言处理任务类别

□**回归**问题：将输入文本映射为一个连续的数值

- 如对作文的打分

- 案件刑期预测

- 罚款金额的预测

□**分类**问题：即判断一个输入的文本所属的类

- 垃圾邮件识别**任务：将一封邮件分为**正常**和**垃圾**两类

- 情感分析**: 将用户的情感分为**褒义**、**贬义**或**中性**三类

自然语言处理任务类别

□**匹配**问题：判断两个输入文本之间的关系

- 复述或非复述两类关系

- 蕴含、矛盾和无关三类关系

- 识别两个输入文本之间的相似性(0到1的数值)

□**解析**问题：对文本中的词语进行标注或识别词语之间的关系

- 词性标注、句法分析

- 分词、命名实体识别等也可转化为解析问题

自然语言处理任务类别

□生成问题：特指根据输入(文本，图片、表格)生成一段自然语言

□典型的文本生成任务


- 机器翻译

- 文本摘要

- 图像描述生成

自然语言处理研究对象与层次


□ NLP的研究由浅入深，可分为形式、语义、推理和语用四个层次




自然语言处理研究对象与层次

□形式方面：研究语言符号层面的处理，研究的是“名”与“名”之间的关系

□如通过编辑距离等计算文本之间的相似度



自然语言处理研究对象与层次




□ **语义**方面：研究语言符号和其背后所要表达的含义之间的关系，即“名”和“实”之间的关系

□ “手机余额不足”和“电话欠费了”，表达方式不同，阐述的事实相同


□ 语义问题也是NLP领域主要关注的问题

自然语言处理研究对象与层次

- ▣ **推理**：在语义研究的基础之上，进一步引入知识的运用
- ▣ 涉及“名”“实”和“知”之间关系，体现了自然语言的知识性



自然语言处理研究对象与层次



- **语用**：复杂，引入了语言所处的环境因素
- 通常表达的是“言外之意”和“弦外之音”
- 同时涉及了“名” “实” “知” “境”四个方面

□ “你真讨厌”

- 字面意义上明显贬义
- 如果是情侣之间的对话，含义可能就不一样了
- 语气、语调以及说话人的表情和动作也会影响其要表达的含义

“层次 x 任务” 二维表

	分类	解析	匹配	生成
形式	文本分类	词性标注 句法分析	搜索	机械式文摘
语义	情感分析	命名实体识别 语义角色标注	问答	机器翻译
推理	隐式情感分析		文本蕴含	写故事结尾
语境	反语			聊天

自然语言处理技术发展历史

□ 自然语言处理技术发展阶段

□ 理性主义

□ 经验主义

小规模专家知识
(理性主义)
1950~1990

语料库统计模型
(经验主义)
1990~2010

深度学习模型
(经验主义)
2010~2017

大规模预训练模型
(经验主义)
2018~2022

大语言模型
(经验主义)
2023至今

- 语料规模、计算能力有限制，早期的NLP采用基于**理性主义**的规则方法
- 通过**专家总结的符号逻辑知识**处理通用的自然语言现象
- 自然语言复杂，基于规则方法在面对实际应用场景中的问题时显得力不从心

自然语言处理技术发展历史

□ 基于语料库的统计NLP

□ 背景：20世纪90年代开始

- 计算机**运算速度**和**存储容量**的快速增加
- 统计学习方法愈发成熟，以语料库为核心的统计学习方法在NLP领域得以大规模应用

□ 成果：词法分析、句法分析、信息抽取、机器翻译和自动问答等领域的研究均取得了一定程度的成功

□ 局限性：

- 需要事先**利用经验性规则**将原始的自然语言输入转化为**向量**形式
- 转化过程(特征提取)需要细致的人工操作和一定的专业知识，被称为特征工程

自然语言处理技术发展历史

□大规模语料库深度学习

□背景：2010年之后，基于深度神经网络的表示学习方法(深度学习)快速发展

□深度学习优势：

- 自动地发现有效特征

- 跨任务迁移的能力：将不同任务在相同的向量空间内进行表示

自然语言处理技术发展历史

□ 大规模语料库深度学习

□ 深度学习优势：

□ 自动地发现有效特征

- 直接端到端地学习各种NLP任务，不再依赖人工设计的特征

- 能根据输入自动地发现可以用于识别或分类等任务的表示

- 深度学习模型在结构上通常包含多层的处理层

 - 底层的处理层接收原始输入，然后对其进行抽象处理，其后的每一层都在前一层的结果上进行更深层次的抽象，最后一层的抽象结果即为输入的一个表示，用于最终的目标任务

 - 抽象处理由模型内部的参数进行控制的，参数更新值根据训练数据上模型的表现，使用反向传播算法学习得到的

- 深度学习可避免统计学习方法中的人工特征提取操作，自动地发现对于目标任务有效的表示

自然语言处理技术发展历史

□大规模语料库深度学习

□优势：

□自动地发现有效特征

□跨任务迁移的能力：将不同任务在相同的向量空间内进行表示

- 传统统计学习方法需要针对不同的任务设计不同的特征，这些特征往往是无法通用的
- 表示学习能够将不同任务在相同的向量空间内进行表示，从而具备跨任务迁移的能力
- 可以跨任务、实现跨语言甚至跨模态的迁移
- 综合利用多项任务、多种语言和多个模态的数据，使得人工智能向更通用的方向迈进了一步

自然语言处理技术发展历史

□大规模语料库深度学习

□成果：

- 在语音识别、计算机视觉等领域，深度学习取得了当时最好的效果
- NLP领域，深度学习同样引发了一系列的变革
- 大幅度提升NLP系统准确率
- 提出序列到序列生成框架

□文本生成：

- 自然语言生成的研究几乎处于停滞状态，除了使用模板生成一些简单的语句，并没有什么太有效的解决办法
 - 逐词的文本生成方法全面提升了生成技术的灵活性和实用性
- 革新了机器翻译、文本摘要和人机对话等任务的技术范式

自然语言处理技术发展历史

□大规模语料库深度学习

□背景：深度学习快速发展

□优势：

- 自动地发现有效特征

- 跨任务迁移的能力：将不同任务在相同的向量空间内进行表示

□成果：大幅度提升NLP系统准确率

□缺点：过度依赖于大规模有标注数据

- 图像: 上百万幅的图像标注了相应的类别(如ImageNet数据集)

- 语音: “语音--文本” 平行语料库也有几十万小时

- NLP: 标注数据往往不够充足,难满足深度学习模型训练的需要

 - 认知类任务所具有的“主观性”特点

 - 任务和领域众多

自然语言处理技术发展历史

□大规模预训练模型

□背景：弥补了NLP标注数据不足的缺点


- 早期的静态词向量预训练模型，后来的动态词向量预训练模型

- 2018年以来，以BERT、GPT为代表的超大规模预训练语言模型

□成果：NLP取得了一系列的突破

- 使得包括阅读理解在内的所有NLP任务的性能都得到了大幅提高，在有些数据集上达到或甚至超过了人类水平

自然语言处理技术发展历史



预训练 + 精调 = 自然语言处理新范式

自然语言处理技术发展历史

□大规模预训练语言模型

□模型预训练(Pre-train)：

- 先在一个原任务上预先训练一个初始模型
- 然后在下游任务(也称目标任务)上继续对该模型进行精调(Fine-tune)，从而达到提高下游任务准确率的目的

□本质：迁移学习(Transfer Learning)思想的一种应用

□问题：同样需要人工标注，原任务标注数据的规模往往也非常有限

- 如何获得更大规模的标注数据呢？

自然语言处理技术发展历史

□大规模预训练语言模型

□数据：

- 文本自身的顺序性就是一种天然的标注数据，通过若干连续出现的词语预测下一个词语(又称语言模型)就可以构成一项原任务
- 图书、网页等文本数据规模近乎无限，可以非常容易地获得超大规模的预训练数据
- 这种不需要人工标注数据的预训练学习方法称为无监督学习 (Unsupervised Learning)
- 学习的过程仍然是有监督的 (Supervised) , 自监督学习 (Self-supervised Learning)

自然语言处理技术发展历史

□大规模预训练语言模型

□模型容量足够大：

- 能够刻画大规模数据中复杂的语言现象，还要求所使用的深度学习模型容量足够大
- 基于自注意力的Transformer模型显著地提升了对于自然语言的建模能力，是近年来具有里程碑意义的进展之一
- 在可容忍的时间内，在如此大规模的数据上训练一个超大规模的Transformer模型，离不开以GPU、TPU为代表的现代并行计算硬件
- 超大规模预训练语言模型完全依赖“蛮力”，在大数据、大模型和大算力的加持下，使自然语言处理取得了长足的进步

自然语言处理技术发展历史

□ 大规模预训练语言模型

□ 模型容量足够大：

□ 如 OpenAI推出的GPT-3

- 1, 750亿个参数


- 无须接受任何特定任务的训练，便可以通过小样本学习完成十余种文本生成任务

 - 如问答、风格迁移、网页生成和自动编曲等

□ 预训练模型已经成为NLP的新范式

自然语言处理技术发展历史

□ 预训练模型参数量趋势





Thanks!
Q&A ?

wuxianyan@njau.edu.cn